

2.8 信息冗余度与自然语言的熵

2.8.1 信源的相关性

1. 含义: 信源符号间的依赖程度.

2. $H_0 > H_1 > H_2 > H_{m+1} > \dots > H_\infty$

冗余度减小
符号相关性越大, 信源熵越小

2.8.2 信源冗余度

对一般离散平稳信源, H_∞ 就是实际信源熵。
理论上只要有传送 H_∞ 的手段, 就能把信源包含的信息全部发送出去。但实际上确定 H_∞ 非常困难, 只好用 H_{m+1} 来代替。 $H_{m+1} > H_\infty$, 所以在传输手段上必然富裕, 这样做实际上就是一种浪费, 特别是有时只能得到 H_1 , 甚至 H_0 , 非常不经济。

这种浪费是由于实际信源符号具有无限记忆长度的相关性, 而又没有求得 H_∞ 的手段。

1. 信源冗余度: $R = 1 - \frac{H_0}{H_\infty}$

2. 熵的相对率: $\eta = \frac{H_\infty}{H_0}$

3. 自然语言的熵:

英文: 27 字母 (含空格) $H_0 = \log 27 = 4.76 \text{ bit/符号}$

认为独立: $H_1 = -\sum_{i=1}^{27} p(c_i) \log p(c_i) = 4.03 \text{ bit/sym}$

视为马尔可夫信源: $H_2 = 3.32$

$H_3 = 3.1$

...

$H_\infty = 1.4$

$R = 1 - \frac{1.4}{4.76} = 71\%$

• 写英语文章时, 71% 是由语言结构定好的, 只有 29% 是写文字的人可以自由选择。100 页的书, 大约只传输 29 页就可以了, 其余 71 页可以压缩掉。信息的冗余度表示信源可压缩的程度。

• 从提高传输效率的观点出发, 总是希望减少或去掉冗余度。但冗余度大的消息抗干扰能力强。能通过前后符号间的关联关系纠正错误。